LAPORAN NOMOR 3

Image Generation Citra Overhead-MNIST menggunakan Conditional GAN

Final Project Deep Learning

Problem Understanding, Baseline CGAN, Modified Conditional DCGAN, Manual Hyperparameter Tuning, dan Evaluasi FID

Hazel Novero Winata
NIM: 2802519114

Problem Understanding Soal 3

Pada soal nomor 3, tujuan utama yang ingin dicapai adalah membangun model deep learning untuk image generation. Model yang digunakan adalah Generative Adversarial Network atau GAN. Berbeda dengan soal nomor 2 yang menggunakan Autoencoder untuk reconstruction, pada soal nomor 3 model tidak bertugas merekonstruksi gambar input, tetapi menghasilkan gambar baru yang menyerupai distribusi gambar asli pada dataset.

Dataset yang digunakan adalah Overhead-MNIST dengan dua kelas sesuai ketentuan NIM dan gender, yaitu Parking Lot dan Storage Tanks. Karena dataset hanya menggunakan dua kelas, model tidak cukup hanya menghasilkan gambar overhead secara umum. Model juga diharapkan mampu menghasilkan gambar berdasarkan kelas tertentu. Ketika label Parking Lot diberikan, generator diharapkan menghasilkan gambar yang menyerupai Parking Lot. Ketika label Storage Tanks diberikan, generator diharapkan menghasilkan gambar yang menyerupai Storage Tanks.

Berdasarkan gambar arsitektur pada soal 3B, model yang digunakan lebih tepat disebut Conditional GAN atau CGAN, bukan vanilla GAN. Hal ini terlihat dari adanya Embedding(labels) pada generator dan discriminator. Pada vanilla GAN, generator hanya menerima random noise sebagai input sehingga model tidak memiliki kontrol terhadap kelas gambar yang dihasilkan. Pada CGAN, generator menerima random noise dan class label. Random noise digunakan sebagai sumber variasi, sedangkan class label digunakan sebagai kondisi agar generator menghasilkan gambar sesuai kelas yang diminta.

Discriminator pada CGAN juga menerima image dan class label. Artinya, discriminator tidak hanya belajar membedakan real image dan fake image, tetapi juga mempertimbangkan apakah gambar tersebut sesuai dengan label kelas yang diberikan. Pendekatan ini sesuai dengan karakter dataset karena Parking Lot dan Storage Tanks memiliki pola visual yang berbeda. Parking Lot cenderung memiliki pola garis, area parkir, blok kecil, dan tekstur berulang, sedangkan Storage Tanks memiliki ciri visual berupa objek seperti tangki atau bentuk lingkaran dari tampak atas.

Evaluasi model dilakukan menggunakan Fréchet Inception Distance atau FID pada data test. FID digunakan untuk mengukur seberapa mirip distribusi fake image dari generator dengan distribusi real image. Semakin kecil nilai FID, semakin baik kualitas distribusi gambar yang dihasilkan. Oleh karena itu, nilai FID baseline digunakan sebagai dasar pembanding untuk menilai apakah modified model pada bagian 3C memberikan peningkatan atau tidak.

Penjelasan Cara Kerja GAN pada Soal 3A

GAN terdiri dari dua jaringan utama, yaitu generator dan discriminator. Generator bertugas menghasilkan fake image dari random noise. Pada awal training, generator belum mengetahui pola data asli sehingga gambar yang dihasilkan biasanya masih berupa noise acak. Discriminator bertugas menilai apakah suatu gambar berasal dari dataset asli atau merupakan gambar palsu yang dibuat oleh generator.

Training GAN dilakukan secara adversarial. Discriminator dilatih agar semakin baik membedakan real image dan fake image. Sebaliknya, generator dilatih agar semakin mampu menghasilkan fake image yang dapat menipu discriminator. Dengan demikian, kedua model saling bersaing. Discriminator berusaha menjadi penilai yang lebih kuat, sedangkan generator berusaha menghasilkan gambar yang semakin mirip dengan data asli.

Pada Conditional GAN, proses tersebut ditambah dengan informasi class label. Generator tidak hanya menerima random noise, tetapi juga label kelas. Discriminator juga tidak hanya menerima image, tetapi juga label kelas. Hal ini membuat model dapat diarahkan untuk menghasilkan gambar berdasarkan kelas tertentu. Karena soal menggunakan dua kelas, yaitu Parking Lot dan Storage Tanks, pendekatan Conditional GAN lebih sesuai dibandingkan vanilla GAN.

Pada saat melatih discriminator, real image diberi target real, sedangkan fake image diberi target fake. Pada saat melatih generator melalui combined CGAN, fake image justru diberi target real. Target ini sengaja digunakan agar generator belajar menghasilkan fake image yang dianggap real oleh discriminator. Proses inilah yang menjadi inti adversarial training pada GAN.

Evaluasi GAN tidak menggunakan accuracy, precision, recall, F1-score, atau confusion matrix sebagai metrik utama kualitas generator. Metrik klasifikasi seperti itu hanya menggambarkan performa discriminator, bukan kualitas gambar yang dihasilkan. Oleh karena itu, pada soal nomor 3 evaluasi utama menggunakan FID untuk membandingkan distribusi fake image dan real image.

Sumber Data dan Ketentuan Kelas

Sumber data yang digunakan adalah dataset Overhead-MNIST yang diberikan untuk soal nomor 2 dan nomor 3. File dataset dibaca dari format IDX, yaitu file image dan label untuk train serta test. File image menyimpan citra grayscale 28 x 28 piksel, sedangkan file label menyimpan kelas dari setiap gambar.

Berdasarkan ketentuan NIM genap dan laki-laki, dua kelas yang digunakan adalah Parking Lot dan Storage Tanks. Pada mapping label dataset, Parking Lot berada pada label asli 4, sedangkan Storage Tanks berada pada label asli 9. Kedua label tersebut kemudian dipetakan ulang menjadi label baru 0 dan 1 agar lebih sederhana untuk training Conditional GAN.

Tabel 1. Mapping kelas yang digunakan pada Soal 3

Label Asli	Label Baru	Kelas	Keterangan
4	0	Parking Lot	Area parkir dari tampak atas, cenderung memiliki garis dan tekstur berulang
9	1	Storage Tanks	Area tangki penyimpanan dari tampak atas, sering memiliki pola objek lebih terang atau melingkar

Loading Dataset

Tahap loading dilakukan dengan membaca file image dan label dalam format IDX. File image memiliki header yang berisi magic number, jumlah gambar, jumlah baris, dan jumlah kolom. File label memiliki header yang berisi magic number dan jumlah label. Setelah header dibaca, data image disusun kembali menjadi array berukuran jumlah data, 28, dan 28.

Output notebook menunjukkan bahwa data train bawaan dataset memiliki shape (68257, 28, 28), sedangkan label train memiliki shape (68257,). Data test bawaan dataset memiliki shape (8520, 28, 28), sedangkan label test memiliki shape (8520,). Hasil ini sesuai dengan karakter Overhead-MNIST sebagai dataset citra kecil berukuran 28 x 28 piksel.

Tabel 2. Hasil loading dataset Overhead-MNIST

Data	Shape	Keterangan
Train images	(68257, 28, 28)	Data image training bawaan dataset
Train labels	(68257,)	Label training bawaan dataset
Test images	(8520, 28, 28)	Data image test bawaan dataset
Test labels	(8520,)	Label test bawaan dataset
Image size	28 x 28 piksel	Gambar grayscale beresolusi kecil

Filtering Kelas Parking Lot dan Storage Tanks

Setelah dataset berhasil dibaca, filtering dilakukan untuk mengambil hanya dua kelas yang sesuai dengan ketentuan tugas, yaitu Parking Lot dan Storage Tanks. Proses filtering dilakukan dengan memilih label asli 4 dan 9. Kelas lain

tetap ada pada dataset Overhead-MNIST, tetapi tidak digunakan dalam modeling soal 3 karena tidak sesuai dengan ketentuan NIM dan gender.

Hasil filtering menunjukkan bahwa data train yang digunakan berjumlah 14.232 gambar dan data test berjumlah 1.784 gambar. Distribusi kelas pada data train dan test relatif seimbang. Pada train set terdapat 7.111 gambar Parking Lot dan 7.121 gambar Storage Tanks. Pada test set terdapat 896 gambar Parking Lot dan 888 gambar Storage Tanks. Keseimbangan kelas ini penting karena CGAN perlu belajar menghasilkan kedua kelas secara adil.

Tabel 3. Distribusi kelas setelah filtering

Subset	Shape Image	Parking Lot	Storage Tanks	Total
Train	(14232, 28, 28)	7.111	7.121	14.232
Test	(1784, 28, 28)	896	888	1.784

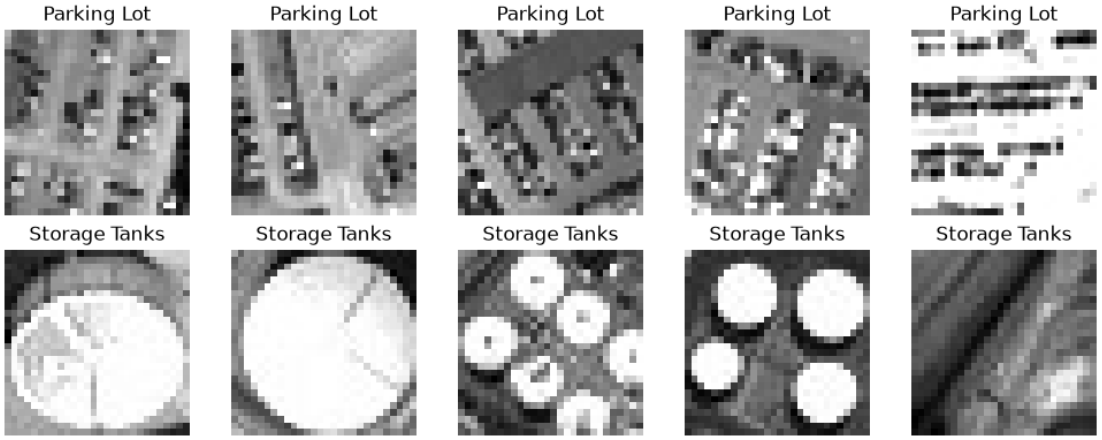
Preprocessing Data untuk GAN

Preprocessing pada soal 3 berbeda dari Autoencoder pada soal 2. Pada soal 2, data di-scaling ke rentang 0 sampai 1 karena output decoder menggunakan sigmoid. Pada soal 3, data gambar diubah ke rentang -1 sampai 1 karena generator menggunakan activation tanh pada output layer. Dengan demikian, output fake image dari generator memiliki skala yang sama dengan real image yang diberikan ke discriminator.

Nilai piksel awal yang berada pada rentang 0 sampai 255 diubah menjadi float32, kemudian dinormalisasi menggunakan rumus (pixel - 127.5) / 127.5. Setelah itu, channel dimension ditambahkan sehingga data memiliki shape (jumlah data, 28, 28, 1). Dimensi terakhir bernilai 1 karena gambar Overhead-MNIST adalah grayscale.

Tabel 4. Hasil preprocessing data untuk GAN

Tahap	Hasil
X_train final	(14232, 28, 28, 1)
X_test final	(1784, 28, 28, 1)
Pixel minimum	-1.0
Pixel maximum	1.0
Jumlah kelas	2 kelas: Parking Lot dan Storage Tanks



Gambar 1. Contoh gambar Parking Lot dan Storage Tanks setelah preprocessing

Baseline CGAN Berdasarkan Gambar dan Perintah Soal

Pada bagian 3B, baseline model dibuat berdasarkan gambar dan perintah soal. Arsitektur baseline menggunakan Conditional GAN dengan input noise dan label pada generator, serta input image dan label pada discriminator. Struktur utama baseline mengikuti gambar soal, yaitu menggunakan layer Linear atau Dense pada generator dan discriminator.

Generator Baseline

Generator baseline menerima dua input, yaitu random noise dan label kelas. Random noise berfungsi sebagai sumber variasi gambar. Label kelas diproses menggunakan Embedding layer, kemudian digabungkan dengan noise menggunakan Concatenate. Setelah itu, input gabungan tersebut dilewatkan ke beberapa Dense layer dengan ukuran 128, 256, 512, dan 1024. Layer terakhir menghasilkan 784 nilai piksel yang kemudian diubah menggunakan Reshape menjadi gambar berukuran 28 x 28 x 1.

Pada gambar dan perintah soal, activation function tidak disebutkan secara eksplisit. Namun, activation function tetap ditambahkan sebagai kebutuhan teknis neural network. Pada hidden layer digunakan LeakyReLU agar model dapat mempelajari pola non-linear. Jika beberapa Dense layer disusun tanpa activation function, model hanya menjadi rangkaian transformasi linear sehingga kemampuan representasinya terbatas. Pada output generator digunakan tanh karena data gambar sudah dinormalisasi ke rentang -1 sampai 1.

Tabel 5. Struktur generator baseline CGAN

Bagian Generator	Layer / Proses	Fungsi
Input 1	Random noise dimensi 100	Sumber variasi gambar
Input 2	Label + Embedding	Memberi kondisi kelas pada generator
Merge	Concatenate noise dan label embedding	Menggabungkan variasi acak dan informasi kelas
Hidden	Dense 128 - 256 - 512 - 1024 + LeakyReLU	Mempelajari representasi non-linear
Output	Dense 784 + tanh, lalu Reshape 28 x 28 x 1	Menghasilkan fake image grayscale

Discriminator Baseline

Discriminator baseline menerima image dan label kelas. Image berukuran 28 x 28 x 1 diubah menjadi vektor menggunakan Flatten, sedangkan label kelas diproses menggunakan Embedding layer. Vektor image dan label embedding kemudian digabungkan menggunakan Concatenate. Hasil gabungan tersebut masuk ke Dense layer berukuran 512, 1024, 1024, dan 512, lalu output akhirnya berupa satu neuron dengan activation sigmoid untuk menentukan apakah gambar dianggap real atau fake.

Pada baseline discriminator, Dropout tidak digunakan agar struktur model tetap mendekati gambar dan perintah soal. Dropout dan teknik regularisasi lain baru digunakan pada modified model karena bagian 3C memang bertujuan melakukan pengembangan arsitektur dan tuning hyperparameter.

Tabel 6. Struktur discriminator baseline CGAN

Bagian Discriminator	Layer / Proses	Fungsi
Input 1	Image 28 x 28 x 1	Real image atau fake image
Input 2	Label + Embedding	Memberi kondisi kelas pada discriminator
Flatten	Image menjadi vektor 784	Menyesuaikan input dengan Dense layer baseline
Hidden	Dense 512 - 1024 - 1024 - 512 + LeakyReLU	Mempelajari pola real/fake berbasis vektor
Output	Dense 1 + sigmoid	Probabilitas real atau fake

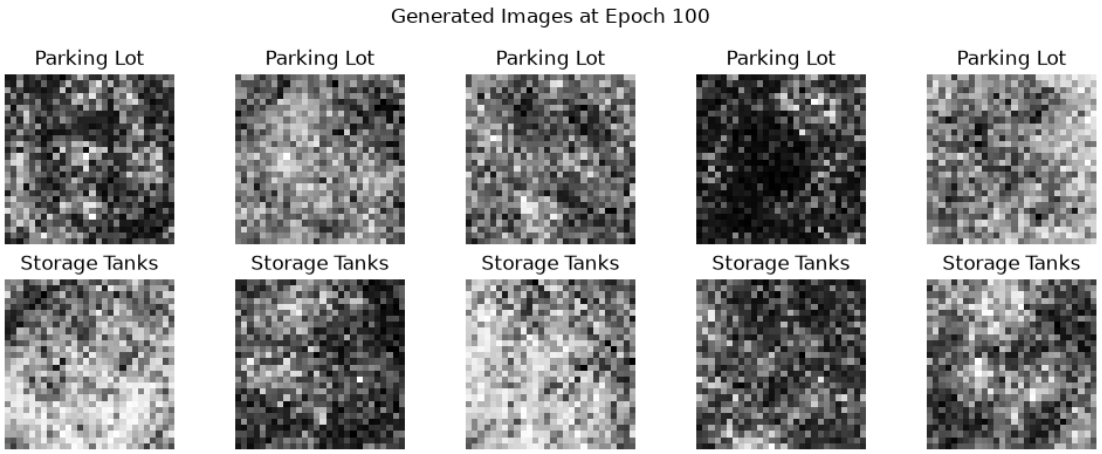
Combined CGAN dan Training Baseline

Setelah generator dan discriminator dibuat, keduanya digabungkan menjadi combined CGAN. Pada combined CGAN, input berupa noise dan label masuk ke generator untuk menghasilkan fake image. Fake image tersebut kemudian diberikan ke discriminator bersama label yang sama. Saat combined CGAN dilatih, discriminator dibuat non-trainable agar bobot yang diperbarui hanya bobot generator. Dengan cara ini, generator belajar menghasilkan fake image yang semakin mampu menipu discriminator.

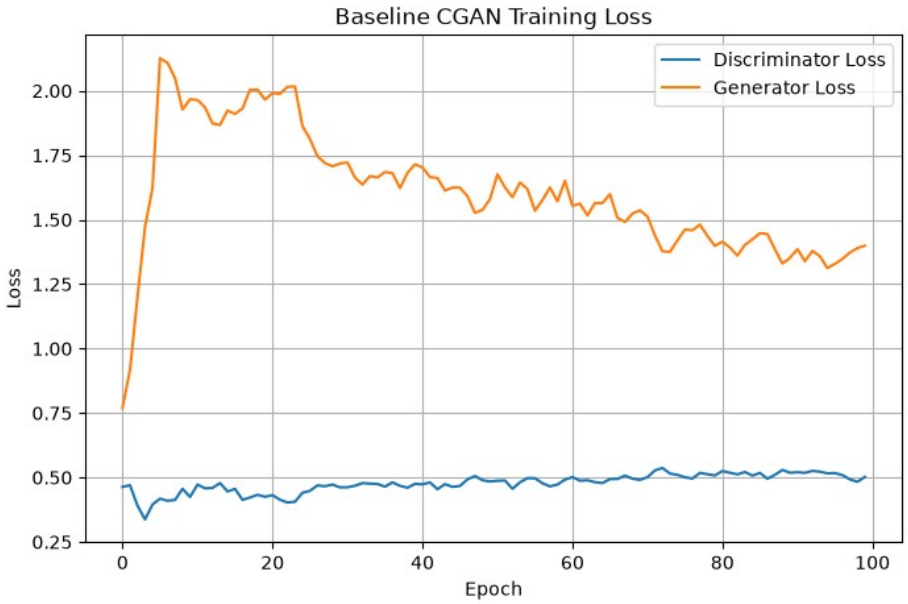
Training baseline dilakukan secara manual karena GAN membutuhkan alur training khusus. Dalam setiap step, discriminator dilatih dengan real image dan fake image. Setelah itu, generator dilatih melalui combined CGAN dengan target fake image dianggap real. Proses ini sesuai dengan konsep adversarial training, yaitu generator dan discriminator saling bersaing selama training.

Tabel 7. Konfigurasi training baseline CGAN

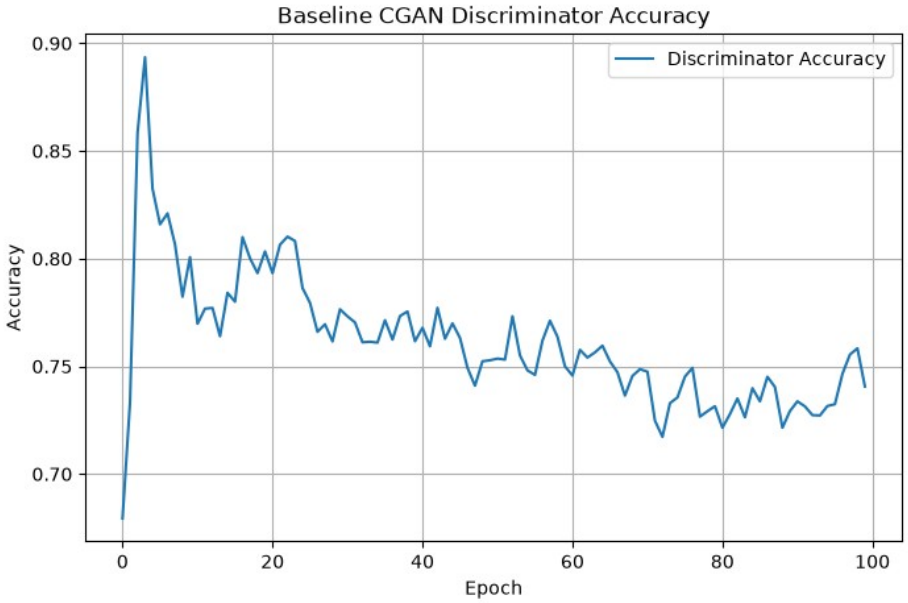
Komponen	Konfigurasi Baseline
Noise dimension	100
Epoch	100
Batch size	128
Learning rate generator	0.00005
Learning rate discriminator	0.00005
Loss	Binary crossentropy
Optimizer	Adam beta_1 = 0.5
Metric tambahan	Discriminator accuracy



Gambar 2. Contoh fake image yang dihasilkan baseline CGAN pada epoch akhir



Gambar 3. Grafik training loss baseline CGAN



Gambar 4. Grafik discriminator accuracy baseline CGAN

Alur Custom Training Loop Baseline

Training GAN tidak menggunakan model.fit() seperti model supervised learning biasa karena generator dan discriminator harus dilatih secara bergantian. Oleh karena itu, notebook menggunakan custom training loop. Dalam setiap step, discriminator dilatih terlebih dahulu menggunakan real image dan fake image, kemudian generator dilatih melalui combined CGAN.

Pada tahap training discriminator, sebagian data real diambil dari X_train dan labelnya diambil dari y_train. Target real image dibuat bernilai 1 pada baseline. Setelah itu, generator membuat fake image dari random noise dan fake label. Fake image tersebut diberi target 0 agar discriminator belajar mengenali gambar palsu.

Setelah discriminator dilatih, tahap berikutnya adalah training generator. Pada tahap ini discriminator dibekukan atau dibuat non-trainable. Noise dan label baru diberikan ke generator, lalu output generator dinilai oleh discriminator. Target yang diberikan adalah 1, karena generator diarahkan agar fake image dianggap real. Dengan cara ini, bobot yang diperbarui adalah bobot generator, sedangkan discriminator hanya berperan sebagai pemberi feedback.

Riwayat training disimpan dalam bentuk discriminator loss, discriminator accuracy, dan generator loss. Nilai ini digunakan untuk memantau stabilitas training, tetapi bukan satu-satunya dasar evaluasi. Pada GAN, loss dapat berfluktuasi karena dua model saling bersaing. Oleh karena itu, hasil visual generated images dan nilai FID tetap menjadi bagian penting dalam analisis akhir.

Evaluasi Baseline dengan FID

Evaluasi baseline dilakukan menggunakan FID pada data test. Fake image dibuat dengan jumlah yang sama seperti real image pada test set, yaitu 1.784 gambar. Label fake image mengikuti label test agar distribusi kelas antara real image dan fake image lebih sebanding. Setelah itu, real image dan fake image diproses menggunakan InceptionV3 sebagai feature extractor.

InceptionV3 digunakan dengan include_top=False dan pooling="avg". Model ini tidak digunakan untuk klasifikasi, melainkan untuk mengambil representasi fitur. Karena InceptionV3 membutuhkan input RGB, gambar grayscale 28 x 28 diubah menjadi RGB dan di-resize ke 75 x 75. Hasil fitur real test memiliki shape (1784, 2048), yang berarti setiap gambar direpresentasikan menjadi 2048 fitur.

Baseline CGAN memperoleh nilai FID sebesar 1159.4017. Nilai ini cukup tinggi, sehingga distribusi fake image baseline masih jauh dari distribusi real image. Secara visual, gambar baseline masih terlihat seperti noise atau tekstur acak dan belum membentuk karakter kelas secara jelas. Hasil ini menjadi dasar untuk membuat modified model pada bagian 3C.

Tabel 8. Hasil evaluasi baseline CGAN menggunakan FID

Model	Jumlah Real Test	Jumlah Fake Test	FID
Baseline MLP CGAN	1.784	1.784	1159.4017

Cara Perhitungan FID pada Notebook

FID dihitung dengan cara membandingkan distribusi fitur real image dan fake image. Langkah pertama adalah menyiapkan gambar agar sesuai dengan input InceptionV3. Karena gambar Overhead-MNIST berbentuk grayscale 28 x 28, gambar diubah kembali ke skala 0 sampai 255, dikonversi menjadi RGB, lalu di-resize menjadi 75 x 75.

Setelah itu, gambar diproses menggunakan preprocess_input dari InceptionV3. Model InceptionV3 dibuat dengan include_top=False dan pooling avg, sehingga output yang diambil bukan kelas prediksi, melainkan vektor fitur. Pada data test, hasil real_test_features memiliki shape (1784, 2048), yang berarti terdapat 1.784 gambar dan setiap gambar direpresentasikan oleh 2.048 fitur.

Fitur real image dan fake image kemudian dibandingkan berdasarkan mean dan covariance. Jika distribusi fitur fake image semakin mirip dengan real image, nilai FID akan semakin kecil. Karena itu, FID cocok digunakan untuk mengevaluasi kualitas distribusi image generation, bukan hanya melihat satu gambar secara individual.

Dasar Pengembangan Modified Model 3C dari Baseline

Pengembangan modified model dilakukan berdasarkan dua temuan utama dari baseline. Pertama, fake image baseline masih terlihat seperti noise dan belum membentuk pola visual kelas dengan jelas. Kedua, nilai FID baseline

sebesar 1159.4017 menunjukkan bahwa distribusi fake image masih cukup jauh dari distribusi real image. Oleh karena itu, modified model perlu diarahkan agar lebih sesuai dengan karakter data gambar.

Keterbatasan utama baseline berasal dari arsitektur yang masih berbasis MLP atau Dense layer. Dense layer memperlakukan gambar sebagai vektor piksel. Akibatnya, hubungan spasial antar piksel kurang dipertahankan. Padahal, citra Overhead-MNIST memiliki pola visual spasial seperti garis parkir, tekstur permukaan, edge, area terang-gelap, dan bentuk objek dari tampak atas.

Berdasarkan kelemahan tersebut, arsitektur pada bagian 3C dimodifikasi menjadi Conditional DCGAN. Model tetap mempertahankan konsep Conditional GAN karena label kelas masih diperlukan untuk mengontrol gambar yang dihasilkan. Namun, generator dan discriminator diubah menjadi convolutional-based model agar lebih mampu menangkap struktur spasial pada citra.

Modified Model Architecture

Modified Generator

Pada modified generator, input tetap terdiri dari random noise dan label kelas. Label diproses menggunakan Embedding layer, kemudian diubah menjadi label map kecil berukuran 7 x 7 x 1. Random noise diproyeksikan menggunakan Dense layer menjadi feature map 7 x 7 x 128. Feature map dari noise dan label map kemudian digabungkan sehingga informasi kelas ikut masuk ke proses pembentukan gambar.

Perbedaan utama dibanding baseline terdapat pada cara generator membentuk gambar. Pada baseline, generator langsung menghasilkan 784 piksel melalui Dense layer. Pada modified generator, gambar dibangun secara bertahap menggunakan Conv2DTranspose. Layer Conv2DTranspose memperbesar feature map dari 7 x 7 menjadi 14 x 14, lalu menjadi 28 x 28. Proses bertahap ini lebih natural untuk image generation karena model belajar membentuk struktur gambar, bukan sekadar menghasilkan deretan piksel.

Batch Normalization digunakan pada generator untuk membantu training menjadi lebih stabil. LeakyReLU digunakan agar model dapat mempelajari pola non-linear dan tetap memiliki gradien pada nilai negatif. Output generator tetap menggunakan tanh karena real image sudah dinormalisasi ke rentang -1 sampai 1.

Tabel 9. Struktur modified generator Conditional DCGAN

Tahap Generator	Layer / Proses	Fungsi
Input	Noise + label	Sumber variasi dan kondisi kelas
Label branch	Embedding label menjadi 7 x 7 x 1	Membuat label map agar informasi kelas masuk secara spasial
Noise projection	Dense 7 x 7 x 128 + BatchNorm + LeakyReLU	Membentuk feature map awal dari noise
Upsampling 1	Conv2DTranspose 64 filter	Memperbesar feature map dari 7 x 7 menjadi 14 x 14
Upsampling 2	Conv2DTranspose 32 filter	Memperbesar feature map menjadi 28 x 28
Output	Conv2D 1 filter + tanh	Menghasilkan fake image 28 x 28 x 1

Modified Discriminator

Pada modified discriminator, image dan label tetap digunakan sebagai input. Label kelas diproses menggunakan Embedding layer, kemudian diubah menjadi label map berukuran 28 x 28 x 1. Label map ini digabungkan dengan image input sehingga discriminator menerima informasi gambar dan informasi label secara bersamaan.

Setelah image dan label map digabungkan, data masuk ke beberapa Conv2D layer. Conv2D lebih sesuai untuk data gambar karena dapat menangkap pola lokal seperti garis, tekstur, edge, area terang-gelap, dan bentuk objek. Layer pertama menggunakan 64 filter untuk menangkap pola visual awal, layer kedua menggunakan 128 filter untuk pola

yang lebih kompleks, dan layer ketiga menggunakan 256 filter untuk memperkaya representasi fitur. Setelah itu, feature map diubah menggunakan Flatten dan masuk ke output sigmoid untuk menghasilkan probabilitas real atau fake.

Dropout digunakan pada modified discriminator sebagai regularisasi. Tujuannya adalah mencegah discriminator terlalu cepat menjadi terlalu kuat. Dalam GAN, discriminator yang terlalu kuat dapat membuat generator kesulitan belajar karena fake image terlalu mudah dikenali sebagai fake. Dropout membantu menjaga keseimbangan antara generator dan discriminator.

Tabel 10. Struktur modified discriminator Conditional DCGAN

Tahap Discriminator	Layer / Proses	Fungsi
Input	Image + label	Menilai real/fake dengan kondisi kelas
Label map	Embedding label menjadi 28 x 28 x 1	Membuat informasi kelas sejajar dengan image input
Concat	Image dan label map menjadi 28 x 28 x 2	Menggabungkan informasi gambar dan kelas
Conv block 1	Conv2D 64 + LeakyReLU + Dropout	Menangkap pola visual awal
Conv block 2	Conv2D 128 + LeakyReLU + Dropout	Menangkap pola lebih kompleks
Conv block 3	Conv2D 256 + LeakyReLU + Dropout	Memperkaya representasi fitur
Output	Flatten + Dense 1 + sigmoid	Menghasilkan probabilitas real/fake

Manual Hyperparameter Tuning

Selain mengubah arsitektur, dilakukan manual hyperparameter tuning. Manual tuning dipilih karena training GAN lebih sensitif dibandingkan model supervised learning biasa. Pada GAN, generator dan discriminator dilatih secara bergantian. Perubahan kecil pada noise dimension, batch size, learning rate, atau dropout dapat membuat hasil training berubah cukup besar. Jika tuning dilakukan terlalu luas seperti GridSearch atau Optuna, waktu training akan sangat panjang dan hasilnya belum tentu stabil. Oleh karena itu, tuning dilakukan secara manual dan terarah berdasarkan hasil baseline serta karakter dataset.

Pada modified model, terdapat tiga eksperimen yang diuji. Semua eksperimen menggunakan arsitektur utama yang sama, yaitu Conditional DCGAN. Perbedaannya terletak pada beberapa hyperparameter penting seperti noise dimension, batch size, steps per epoch, dan learning rate. Semua eksperimen menggunakan one-sided label smoothing dengan real label 0.9 dan dropout rate 0.3 pada discriminator.

Tabel 11. Konfigurasi manual hyperparameter tuning modified model

Eksperimen	Noise Dim	Batch Size	Steps/ Epoch	Epoch	G LR	D LR	Real Label	Dropout
Exp1 Noise100 BS128	100	128	100	150	0.0002	0.0001	0.9	0.3
Exp2 Noise128 BS128	128	128	100	150	0.0002	0.0001	0.9	0.3
Exp3 Noise100 BS64	100	64	200	150	0.0001	0.0001	0.9	0.3

Experiment 1 digunakan sebagai konfigurasi modified awal yang masih cukup dekat dengan baseline. Noise dimension 100 merupakan nilai umum pada GAN, batch size 128 membantu training lebih stabil, dan learning rate generator dibuat lebih besar daripada discriminator agar generator memiliki kesempatan belajar lebih aktif.

Experiment 2 menaikkan noise dimension dari 100 menjadi 128. Tujuannya adalah memberi ruang latent yang lebih luas kepada generator. Dengan sumber variasi yang lebih besar, generator diharapkan dapat menghasilkan fake image yang lebih beragam. Nilai 128 masih wajar untuk gambar 28 x 28 grayscale sehingga model tidak menjadi terlalu berat.

Experiment 3 menurunkan batch size menjadi 64 dan learning rate menjadi 0.0001 untuk generator dan discriminator. Batch size yang lebih kecil membuat update bobot terjadi lebih sering, sedangkan learning rate yang lebih rendah membuat proses training lebih hati-hati. Karena batch size lebih kecil, steps per epoch dinaikkan menjadi 200 agar jumlah update dalam satu epoch tetap cukup.

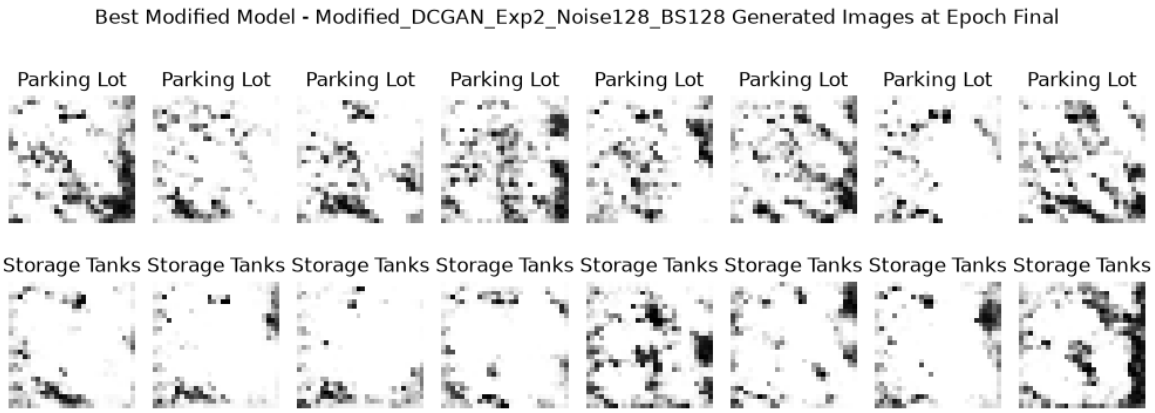
Training dan Evaluasi Modified Model

Training modified model dilakukan menggunakan custom training loop seperti pada baseline. Setiap step terdiri dari training discriminator dengan real image, training discriminator dengan fake image, dan training generator melalui combined CGAN. Perbedaannya adalah generator dan discriminator pada modified model sudah menggunakan arsitektur convolutional. Setelah setiap model selesai dilatih, fake image dibuat berdasarkan label pada test set, kemudian FID dihitung dengan fitur InceptionV3 yang sama seperti baseline.

Fitur real test images dihitung satu kali menggunakan InceptionV3 dan disimpan sebagai real_test_features dengan shape (1784, 2048). Hal ini dilakukan agar evaluasi setiap modified model lebih efisien. Setiap kandidat modified model kemudian menghasilkan 1.784 fake image, jumlah yang sama dengan data test, sehingga perhitungan FID dilakukan secara adil.

Tabel 12. Hasil manual hyperparameter tuning berdasarkan FID

Rank	Model	Noise Dim	Batch Size	Steps/Epoch	Epoch	FID
1	Modified_DCGAN_Exp2_Noise128_BS128	128	128	100	150	1111.724735
2	Modified_DCGAN_Exp3_Noise100_BS64	100	64	200	150	1114.753623
3	Modified_DCGAN_Exp1_Noise100_BS128	100	128	100	150	1141.634137



Gambar 5. Visualisasi fake image dari best modified model

Pemilihan Best Modified Model

Berdasarkan hasil evaluasi, model terbaik adalah Modified_DCGAN_Exp2_Noise128_BS128 dengan FID sebesar 1111.724735. Model ini memiliki FID paling rendah dibandingkan dua eksperimen modified lainnya dan juga lebih baik daripada baseline MLP CGAN yang memiliki FID sebesar 1159.4017.

Experiment 1 sudah menunjukkan perbaikan dari baseline karena FID turun dari 1159.4017 menjadi 1141.634137. Hal ini menunjukkan bahwa perubahan arsitektur dari MLP CGAN menjadi Conditional DCGAN memang memberikan dampak positif. Namun, Experiment 1 masih menggunakan noise dimension 100, sehingga variasi input generator lebih terbatas dibandingkan Experiment 2.

Experiment 2 menghasilkan FID terbaik karena noise dimension 128 memberi generator ruang latent yang lebih luas untuk menghasilkan variasi gambar, sementara batch size 128 tetap menjaga training cukup stabil. Kombinasi generator learning rate 0.0002 dan discriminator learning rate 0.0001 juga membantu menjaga keseimbangan antara generator dan discriminator. Generator tetap dapat belajar cukup aktif, sedangkan discriminator tidak terlalu cepat mendominasi.

Experiment 3 menghasilkan FID sebesar 1114.753623, sangat dekat dengan Experiment 2, tetapi masih sedikit lebih tinggi. Hal ini menunjukkan bahwa batch size 64 dan learning rate 0.0001 cukup stabil, tetapi belum menghasilkan distribusi fake image yang lebih baik daripada konfigurasi noise dimension 128 dan batch size 128. Dengan demikian, Experiment 2 tetap dipilih sebagai final modified model.

Tabel 13. Konfigurasi best modified model

Komponen	Best Modified Model
Model	Modified_DCGAN_Exp2_Noise128_BS128
Architecture	Conditional DCGAN
Noise dimension	128
Batch size	128
Steps per epoch	100
Epoch	150
Generator learning rate	0.0002
Discriminator learning rate	0.0001
Real label smoothing	0.9
Dropout rate	0.3
FID	1111.724735

Perbandingan Baseline dan Best Modified Model

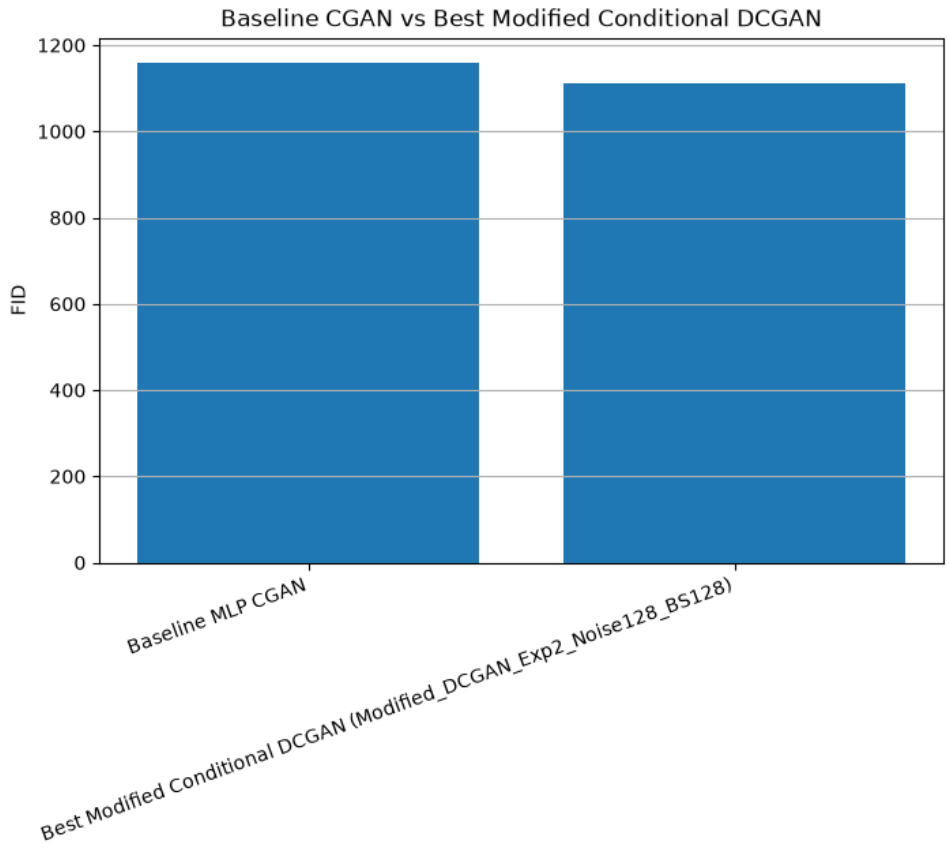
Perbandingan utama dilakukan antara baseline MLP CGAN dan best modified Conditional DCGAN. Baseline menghasilkan nilai FID sebesar 1159.4017, sedangkan best modified model menghasilkan FID sebesar 1111.724735. Karena FID yang lebih rendah menunjukkan distribusi fake image yang lebih mendekati distribusi real image, hasil ini membuktikan bahwa modified model memberikan peningkatan dibandingkan baseline.

Persentase improvement dihitung dari penurunan FID baseline ke FID best modified model. Hasil perhitungan menunjukkan improvement sebesar 4.11%. Nilai ini tidak terlalu besar, tetapi tetap valid karena arah perbaikannya jelas dan konsisten dengan tujuan modifikasi, yaitu menurunkan FID. Pada tugas image generation dengan GAN, peningkatan kecil tetap bermakna karena training GAN sangat sensitif dan tidak selalu stabil.

Tabel 14. Perbandingan baseline dan best modified model

Model	FID	Keterangan
Baseline MLP CGAN	1159.4017	Model baseline berdasarkan gambar soal dengan Dense/Linear layer
Best Modified Conditional DCGAN	1111.724735	Model terbaik hasil modifikasi dan manual tuning

Improvement	4.11%	Penurunan FID dari baseline ke best modified model



Gambar 6. Perbandingan FID baseline dan best modified model

Analisis Visual Hasil Generated Images

Secara visual, hasil best modified model masih belum sempurna dan masih terlihat agak abstrak. Hal ini masih wajar karena GAN harus belajar menghasilkan gambar baru tanpa target pasangan seperti pada Autoencoder. Selain itu, data hanya berukuran 28 x 28 grayscale sehingga detail visual seperti bentuk tangki atau garis parkir tidak selalu mudah terbentuk secara jelas.

Meskipun demikian, dibandingkan baseline, hasil modified model mulai menunjukkan pola yang lebih terstruktur. Pada kelas Parking Lot, gambar mulai menunjukkan tekstur dan pola area kecil yang lebih ramai. Pada kelas Storage Tanks, gambar mulai menunjukkan perbedaan area gelap dan terang, walaupun bentuk tangki belum selalu terlihat jelas. Analisis visual ini mendukung hasil FID bahwa modified model lebih baik daripada baseline, meskipun peningkatannya belum sangat besar.

Dalam evaluasi GAN, visualisasi tidak digunakan sebagai satu-satunya dasar keputusan karena visual dapat bersifat subjektif. Oleh karena itu, FID tetap menjadi metrik utama. Visualisasi digunakan sebagai pendukung untuk melihat apakah model mengalami mode collapse, menghasilkan noise murni, atau mulai membentuk pola visual yang masuk akal.

Alasan Modified Model Lebih Baik daripada Baseline

Modified model lebih baik daripada baseline karena arsitektur Conditional DCGAN lebih sesuai untuk data gambar. Baseline MLP CGAN menggunakan Dense layer, sehingga gambar diproses sebagai vektor piksel dan hubungan spasial antar piksel kurang dipertahankan. Sebaliknya, modified model menggunakan convolutional layer yang lebih mampu menangkap struktur visual pada citra.

Pada generator, Conv2DTranspose membantu model membangun gambar secara bertahap dari feature map kecil menjadi gambar 28 x 28. Proses ini lebih natural untuk image generation dibandingkan langsung menghasilkan 784 piksel melalui Dense layer. Dengan proses bertahap, generator memiliki peluang lebih besar untuk membentuk pola visual yang terstruktur.

Pada discriminator, Conv2D membantu model mengenali pola lokal seperti garis, tekstur, edge, area terang-gelap, dan bentuk objek. Discriminator yang lebih mampu memahami pola gambar dapat memberikan feedback yang lebih baik kepada generator. Feedback yang lebih baik membuat generator dapat belajar menghasilkan fake image yang distribusinya lebih mendekati real image.

Penggunaan Batch Normalization, Dropout, LeakyReLU, dan label smoothing juga membantu proses training menjadi lebih stabil. Teknik-teknik ini tidak ditambahkan secara acak. Batch Normalization membantu kestabilan aktivasi pada generator, LeakyReLU menjaga aliran gradien, Dropout mengurangi risiko discriminator terlalu dominan, dan one-sided label smoothing mencegah discriminator terlalu percaya diri.

Hasil eksperimen mendukung alasan tersebut. Semua modified model memiliki FID lebih rendah daripada baseline atau sangat mendekati baseline yang lebih baik, dan best modified model berhasil menurunkan FID dari 1159.4017 menjadi 1111.724735. Dengan demikian, modifikasi arsitektur dan tuning hyperparameter memberikan perbaikan yang terukur terhadap kualitas distribusi gambar.

Catatan Evaluasi dan Keterbatasan

Meskipun best modified model berhasil menurunkan FID dibandingkan baseline, nilai FID yang diperoleh masih cukup tinggi. Hal ini menunjukkan bahwa model belum menghasilkan gambar yang sepenuhnya menyerupai distribusi real image. Kondisi ini masih masuk akal karena GAN sulit dilatih, terutama pada gambar 28 x 28 grayscale yang memiliki detail visual terbatas.

FID juga dihitung menggunakan InceptionV3 yang awalnya dilatih pada ImageNet dengan gambar natural RGB. Sementara itu, Overhead-MNIST adalah gambar grayscale beresolusi kecil dari tampak atas. Karena domain data berbeda, nilai absolut FID dapat terlihat tinggi. Oleh karena itu, interpretasi utama pada laporan ini difokuskan pada perbandingan baseline dan modified model dengan prosedur evaluasi yang sama.

Hasil visual juga menunjukkan bahwa fake image dari best modified model belum sepenuhnya jelas. Namun, tujuan bagian 3C adalah menunjukkan proses modifikasi arsitektur, tuning hyperparameter, dan evaluasi apakah modified model lebih baik daripada baseline. Berdasarkan penurunan FID dari 1159.4017 menjadi 1111.724735, modified model berhasil memberikan perbaikan yang terukur.

Kesesuaian dengan Instruksi Soal

Pengerjaan nomor 3 sudah mencakup penjelasan cara kerja GAN pada bagian 3A, pembuatan baseline arsitektur sesuai gambar soal pada bagian 3B, evaluasi distribusi citra menggunakan FID pada data test, serta modifikasi arsitektur dan hyperparameter tuning pada bagian 3C. Model menggunakan dua kelas sesuai ketentuan NIM dan gender, yaitu Parking Lot dan Storage Tanks.

Baseline dibuat sebagai Conditional GAN karena gambar soal menunjukkan penggunaan Embedding(labels). Modified model dikembangkan menjadi Conditional DCGAN agar lebih sesuai dengan data gambar. Evaluasi dilakukan secara

konsisten menggunakan FID, dengan jumlah fake image yang sama seperti jumlah real image pada test set. Dengan demikian, alur eksperimen sudah sesuai dengan tujuan soal dan rubrik penilaian.

Kesimpulan Akhir Nomor 3

Berdasarkan seluruh proses pengerjaan nomor 3, model image generation berhasil dibuat menggunakan Conditional GAN sesuai gambar dan perintah soal. Model yang digunakan bukan vanilla GAN karena generator dan discriminator sama-sama menerima class label melalui embedding. Hal ini sesuai dengan kebutuhan dataset yang hanya menggunakan dua kelas, yaitu Parking Lot dan Storage Tanks.

Dataset berhasil dibaca dari file IDX, kemudian difilter menjadi dua kelas sesuai ketentuan NIM genap laki-laki. Data train setelah filtering berjumlah 14.232 gambar dan data test berjumlah 1.784 gambar. Nilai piksel dinormalisasi ke rentang -1 sampai 1 agar sesuai dengan output generator yang menggunakan tanh. Data juga diberi channel dimension sehingga shape akhir menjadi (jumlah data, 28, 28, 1).

Baseline CGAN pada bagian 3B dibuat mengikuti gambar soal dengan arsitektur Dense/Linear layer pada generator dan discriminator. Activation function seperti LeakyReLU, tanh, dan sigmoid ditambahkan sebagai kebutuhan implementasi agar model dapat belajar secara non-linear, output generator sesuai skala data, dan discriminator dapat menghasilkan probabilitas real/fake. Baseline memperoleh FID sebesar 1159.4017.

Pada bagian 3C, baseline dikembangkan menjadi Conditional DCGAN. Modified generator menggunakan Conv2DTranspose untuk membangun gambar secara bertahap, sedangkan modified discriminator menggunakan Conv2D untuk menangkap struktur spasial pada gambar. Manual hyperparameter tuning dilakukan dengan tiga konfigurasi utama yang menguji noise dimension, batch size, steps per epoch, dan learning rate.

Hasil terbaik diperoleh oleh Modified_DCGAN_Exp2_Noise128_BS128 dengan FID sebesar 1111.724735. Model ini menurunkan FID sekitar 4.11% dibandingkan baseline. Dengan demikian, modified model berhasil memberikan improvement terhadap baseline, meskipun hasil visual masih belum sempurna dan masih agak abstrak.

Alasan utama modified model lebih baik adalah karena arsitektur convolutional lebih sesuai untuk data gambar dibandingkan MLP berbasis Dense layer. Convolutional layer mampu menangkap pola spasial seperti garis, tekstur, edge, dan area kontras. Selain itu, kombinasi Batch Normalization, Dropout, LeakyReLU, label smoothing, dan tuning hyperparameter membantu menjaga stabilitas training GAN. Oleh karena itu, Modified_DCGAN_Exp2_Noise128_BS128 dipilih sebagai final modified model pada bagian 3C.

Sumber dan Referensi

Dataset utama yang digunakan berasal dari dataset Overhead-MNIST yang diberikan untuk soal nomor 2 dan nomor 3. File yang digunakan berupa file IDX image dan label untuk train serta test. Dataset diproses ulang menjadi dua kelas sesuai ketentuan, yaitu Parking Lot dan Storage Tanks.

- Goodfellow, I. et al. (2014). Generative Adversarial Nets. Advances in Neural Information Processing Systems.
- Mirza, M., & Osindero, S. (2014). Conditional Generative Adversarial Nets.
- Radford, A., Metz, L., & Chintala, S. (2016). Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks.
- Heusel, M. et al. (2017). GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium. Advances in Neural Information Processing Systems.
- Szegedy, C. et al. (2016). Rethinking the Inception Architecture for Computer Vision.
- Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization.
- Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift.
- TensorFlow-Keras documentation: Dense, Embedding, Conv2D, Conv2DTranspose, BatchNormalization, Dropout, Adam, and InceptionV3.